

Aplicación móvil para detección de cansancio entre conductores

Oscar Huaco Limache y Elsa Becerra Tupes

Universidad Nacional de Moquegua

Inteligencia Artificial II

Honorio Apaza Alanoca

17 de diciembre de 2023

Introducción

Según los datos proporcionados por Planzer, Perú presenta una tasa de mortalidad por accidentes de tránsito de 23 por cada 10 mil vehículos, situándose como el cuarto país con mayor índice a nivel mundial, después de Bangladesh, China y Sri Lanka. Esta clasificación se ha derivado al calcular la misma tasa utilizando la información del Ministerio de Transportes y Comunicaciones (MTC) sobre los accidentes de tránsito ocurridos en el año 2008, enfocándonos en las primeras 50 empresas de ómnibus involucradas en dichos incidentes. (Planzer, 2006)

El sueño o somnolencia es una de las principales causas de accidentes en carreteras, cuando se maneja durante muchas horas seguidas, o se conduce en horarios nocturnos, la fatiga puede provocar que los reflejos y sentidos no actúen de la misma forma que lo harían en situaciones normales. (CCIMA Señalizaciones, s. f.)

Pestañear y dormitar durante la conducción reflejan un nivel extremo de fatiga y deuda de sueño. Los conductores fatigados o somnolientos disminuyen progresivamente el nivel de atención y concentración durante el manejo y pierden capacidad de respuesta ante condiciones que exigen reacciones inmediatas cuando circulan por la ciudad o las carreteras.

Por lo tanto se propone el uso de Técnicas de Deep Learning en imágenes de expresiones faciales que nos permita detectar los micro sueños y señales de somnolencia en los conductores interprovinciales con el fin de reducir la tasa de accidentes vehiculares causados por el sueño y sus derivados.

Capítulo I: Recopilación de la información

Somnolencia y cansancio

De acuerdo con fuentes externas, se estima que entre el 4% y el 30% de los accidentes en carreteras se originan debido al cansancio o la somnolencia durante la conducción. (Horne & Reyner, 1995). Según el informe de la National Sleep Foundation (NSF), las circunstancias que rodean estos incidentes son las siguientes: suelen ocurrir durante la noche, generalmente entre las 00:00 y las 7:00 horas, así como en el horario vespertino entre las 13:00 y las 15:00 horas. Además, el conductor suele estar solo, la unidad se desvía inadvertidamente de la ruta o invade el carril contrario, y el conductor no muestra signos de haber intentado una maniobra evasiva para evitar la colisión. (National Center for Sleep Disorders Research, 1998)

Ilustración 1

Estadística de accidentes vehiculares del año 2007 al 2017





Ilustración 2

Estadística de número de muertos y heridos por accidente



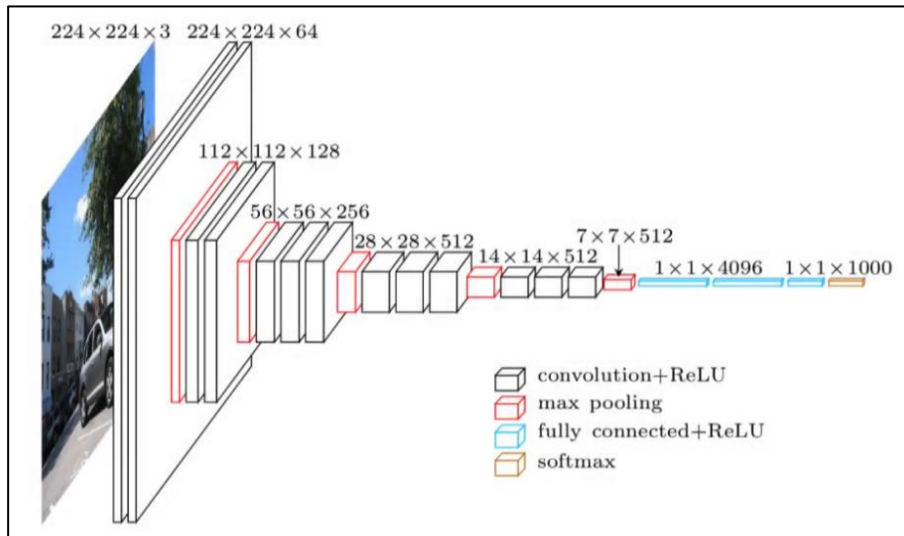
Redes neuronales convolucionales

La red neuronal convolucional (CNN, por sus siglas en inglés) son una extensión de las redes neuronales convencionales y han vuelto muy populares en los últimos años debido a su capacidad para procesar grandes cantidades de datos con alta precisión. Las CNN se utilizan en una variedad de aplicaciones, como la identificación de objetos en imágenes médicas, la detección de fraude en transacciones financieras y la identificación de rostros en fotografías.

Las CNN son capaces de aprender características complejas de datos de entrada mediante la aplicación de filtros convolucionales y capas de agrupación. Estas características se utilizan para clasificar y etiquetar datos de entrada.

Ilustración 3

Forma particular de las convoluciones



Una convolución consiste en tomar grupos de píxeles cercanos de la imagen de entrada e ir operando matemáticamente contra una pequeña matriz a la que se denomina kernel conocida como filtro. Ese kernel recorre todas las neuronas de entrada – de izquierda a derecha y de arriba hacia abajo – y genera una nueva matriz de salida, que será la nueva capa de neuronas ocultas, y que también se conoce como la matriz de activación. La convolución será tal si y sólo si el kernel es real y simétrico (Diego calvo, 2019)

Un filtro con solo un valor uno en el centro terminare recorriendo la imagen sin realiza modificación alguna a los pixeles.

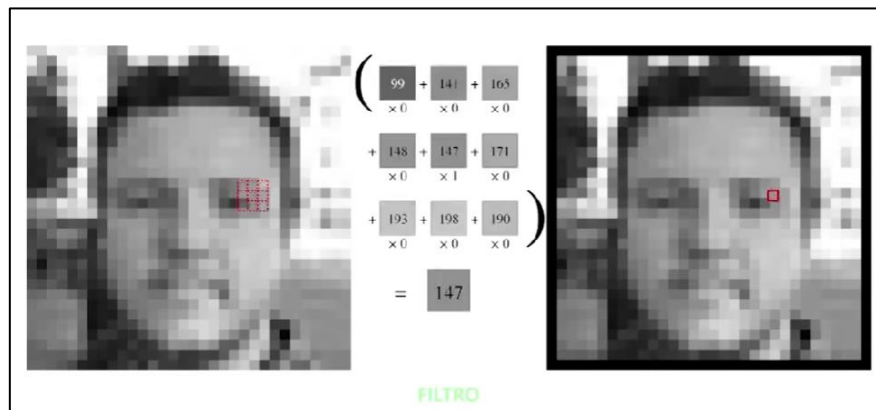
Ilustración 4

Primer prueba de filtro



Ilustración 5

Resultado de primera prueba



El siguiente filtro permite detectar bordes verticales en las imágenes

Ilustración 6

Segunda prueba de filtro

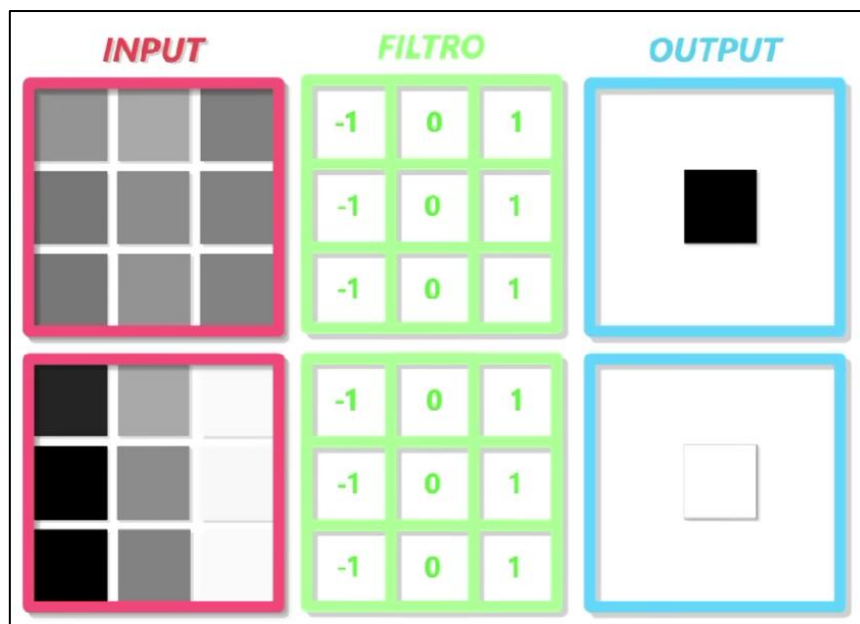
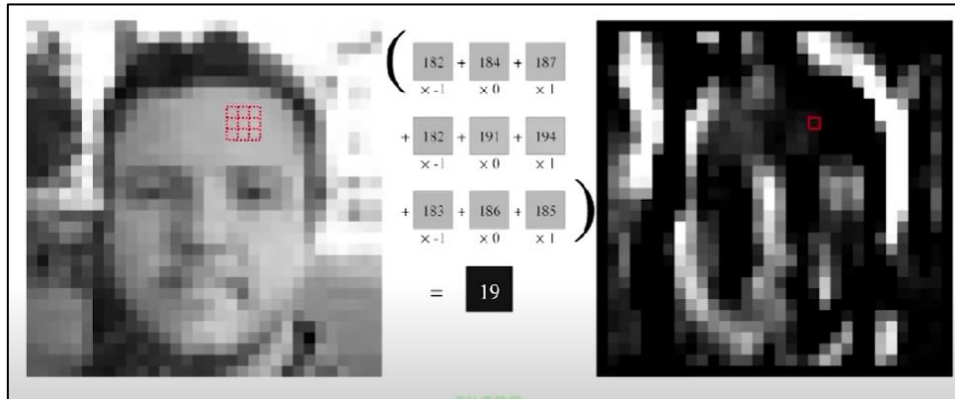


Ilustración 7

Resultado de segunda prueba



Mientras mas filtro se aplican mas datos de la imagen original estamos tomando en un solo pixel

Ilustración 8

Información almacenada por convolución

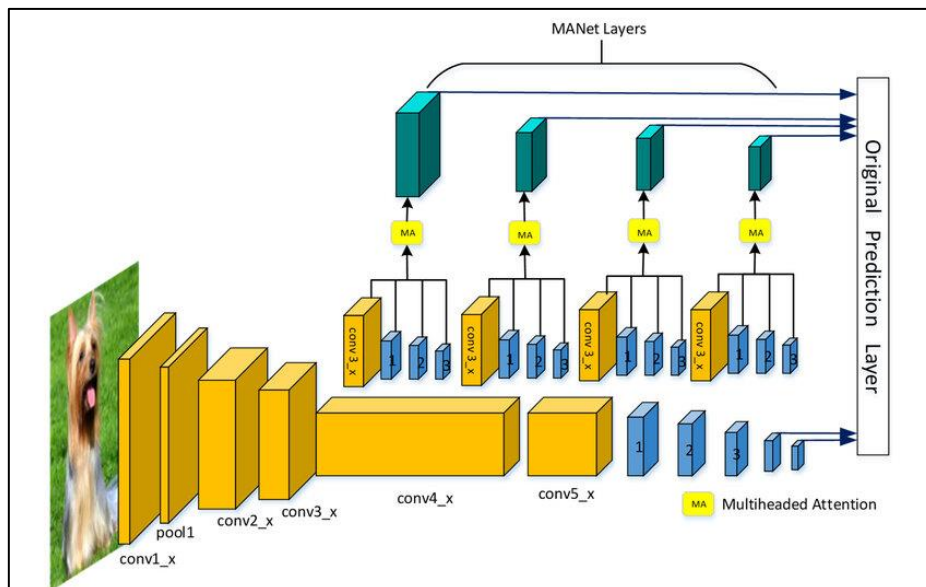


SSD

El SSD es un algoritmo de detección de objetos potente y eficiente que ha ganado popularidad debido a su capacidad para procesar imágenes en tiempo real, manteniendo altos niveles de precisión. A diferencia de otros métodos de detección de objetos que requieren múltiples etapas de procesamiento, SSD combina todos los pasos necesarios en un solo paso a través de la red neuronal. Esto no solo acelera el proceso de detección, sino que también reduce los recursos computacionales necesarios, lo que lo convierte en una opción ideal para aplicaciones en tiempo real.

El enfoque SSD se basa en una red convolucional de retroalimentación que produce una colección de cuadros delimitadores de tamaño fijo y puntuaciones para la presencia de instancias de clase de objeto en esos cuadros, seguidas de una supresión no máxima paso para producir las detecciones finales. Las primeras capas de red se basan en una arquitectura estándar utilizada para la clasificación de imágenes de alta calidad.

Ilustración 9
Single Shot multibox Detector



Capítulo II: Procedimiento

Recopilación de la data

El conjunto de datos de subregiones geográficas(GEOGRAPHICAL SUBREGION DATASET) es una colección de datos que clasifica el mundo en áreas geográficas más pequeñas y específicas. Estas subregiones pueden basarse en diversos criterios, como fronteras políticas, características físicas o características culturales.

Contiene 1700 muestras distribuidas uniformemente en 17 subregiones geográficas. Cada región contiene 100 imágenes.

Todas las muestras se recogen de la misma fuente que las muestras de entrenamiento y se caracterizan como selfis con cámara frontal de teléfono inteligente.


Detección de rostros

Se utiliza MediaPipe BlazeFace para la detección de rostro, el cual un modelo ligero de aproximadamente 224KB utilizado para la detección de uno o múltiples rostros en una imagen capturada por la cámara de un celular o cámara web, es un tipo de red neuronal convolucional basado en SSD con un codificador.

Un parpadeo se puede dimensionar como la distancia entre el párpado superior e inferior, cuando esta distancia tiende a cero se puede determinar que el ojo ha emitido un parpadeo. La detección de parpadeos de basa en determinar esta distancia y utilizar un umbral mínimo próximo a cero que indique un parpadeo.

Ilustración 10

Detección de rostros



Entrenamiento

Python es un lenguaje de programación de alto nivel que es ampliamente utilizado para el aprendizaje automático.

Python cuenta con una amplia biblioteca de funciones y módulos que facilitan el desarrollo de redes neuronales. Esta biblioteca incluye módulos para la carga de datos, la creación de redes neuronales, el entrenamiento de redes neuronales y la evaluación del rendimiento de las redes neuronales. (Goodfellow, 2016)

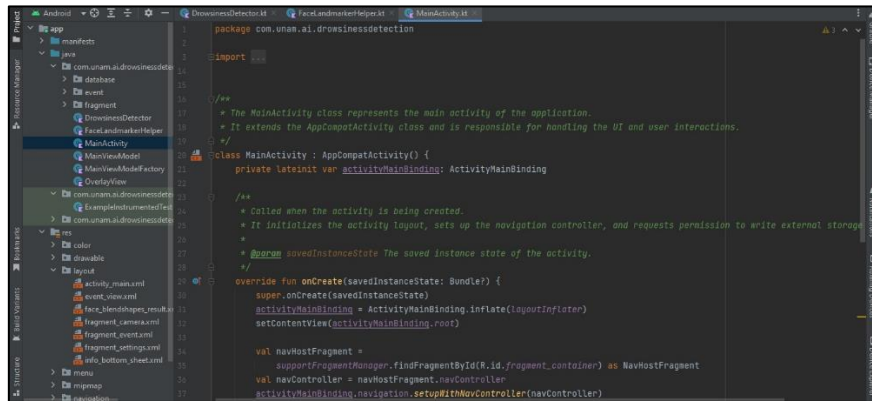
Código

Android studio

Se utilizó Android studio para crear la interfaz interactiva de la detección y guardado de registro. Se optó por esta herramienta ya que es un IDE completo y bien integrado que incluye todas las herramientas que los desarrolladores necesitan para crear aplicaciones Android, desde el editor de código hasta las herramientas de depuración y análisis.

Ilustración 11

Código en Android Studio



Interfaz

Se desarrollaron 3 interfaz con las que los usuarios pueden interactuar:

La interfaz de detección es donde se detecta el rostro y se ejecuta la alarma en caso se detecte micro sueño

La interfaz de registros es donde se guardan las detecciones anteriores con fecha, hora, tipo de detección y la evidencia fotográfica.

La interfaz de configuración permite cambiar el umbral de la detección

Ilustración 12

Interfaz de detección

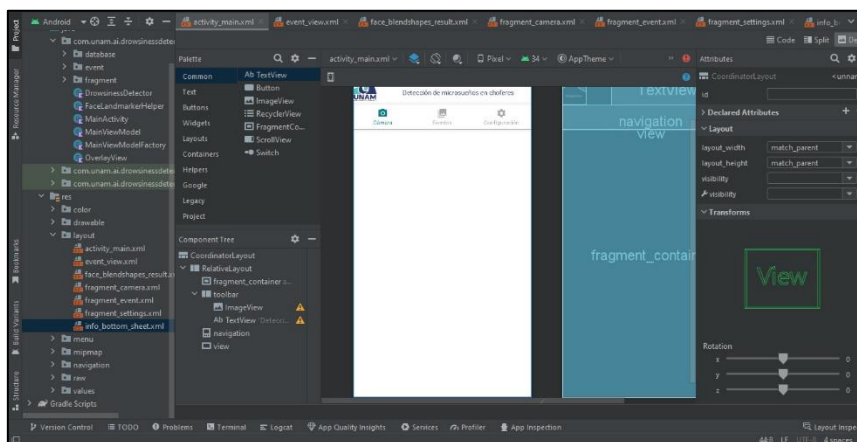


Ilustración 13

Interfaz de registro

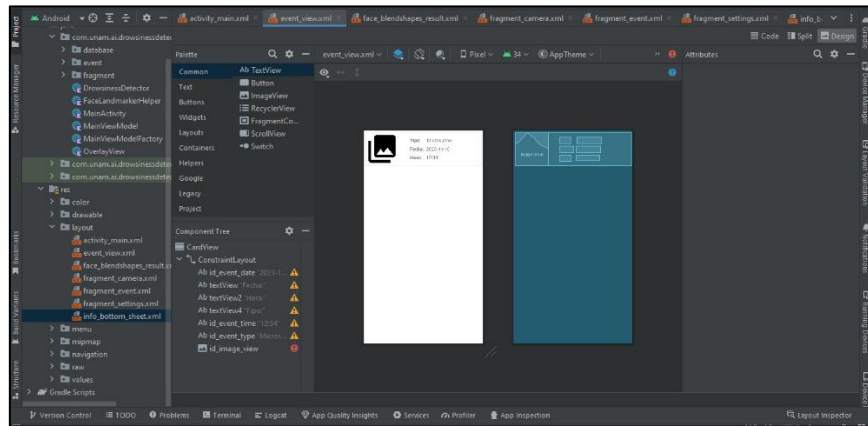
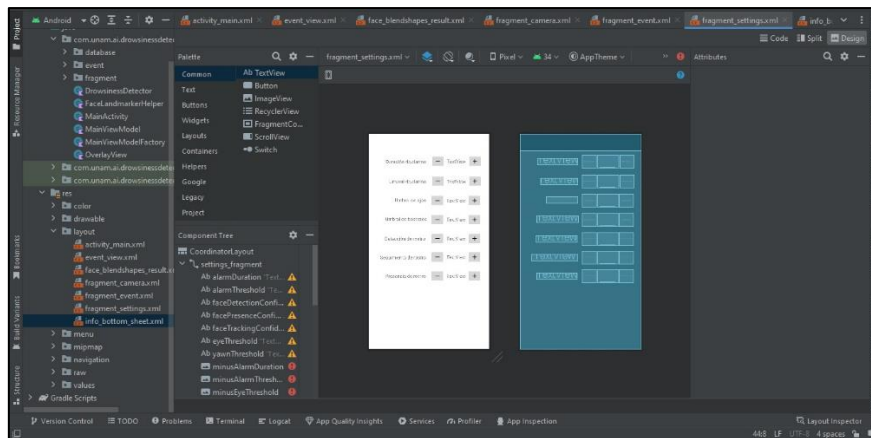


Ilustración 14


Interfaz de configuración



Capítulo III: Análisis y descripción de resultados


El resultado final es una aplicación móvil que va a detectar nuestro rostro donde identifica los ojos y boca, estos serán enmarcados por diferentes puntos que nos ayudarán a identificar los micro sueños.

Ilustración 15
Medidas de detección



En la aplicación también aparecen parámetros de la detección y esta detección se actualiza en cada movimiento que se realice.


Ilustración 16
Aplicación de detección



Después de realizar la detección se realiza una suma y división entre los parámetros más alejados verticalmente y horizontalmente, si este resultado supera el umbral se detecta el micro sueño y suena una alarma.

Ilustración 17

Alerta de detección de micro sueño



CONCLUSIONES

La aplicación móvil para la detección de cansancio entre conductores representa una herramienta clave en la mejora de la seguridad vial, con beneficios tanto para los conductores individuales como para la sociedad en general. Sin embargo, su éxito dependerá de la implementación efectiva, la colaboración con las autoridades y el enfoque ético en su desarrollo y uso.

La aplicación contribuirá significativamente a la reducción de accidentes de tráfico causados por la fatiga del conductor, mejorando así la seguridad en las carreteras además de brindar un nuevo enfoque al modo de monitoreo de actividades de los conductores.

Se vislumbra un camino de desarrollo continuo para la aplicación, con posibilidades de integrar avances tecnológicos, expandir su utilidad y adaptarla a las dinámicas cambiantes del entorno vial, consolidándola como una herramienta esencial para la seguridad en el transporte.

REFERENCIAS

Horne, J. A., & Reyner, L. A. (1995). Sleep related vehicle accidents. *BMJ*, 310(6979), 565-7.

Sagberg, F. (1999). Road accidents caused by drivers falling asleep. *Accid Anal Prev*, 31(6), 639-49.

Planzer, R. (2006). La seguridad vial en la región de América Latina y el Caribe. Situación actual y desafíos. Santiago de Chile: Naciones Unidas - Comisión Económica para América Latina y el Caribe (CEPAL).

National Center for Sleep Disorders Research and National Highway Traffic Safety Administration Expert Panel on Driver Fatigue and Sleepiness. (1998). Drowsy driving and automobile crashes: report and recommendations. Washington DC: National Heart, Lung, and Blood Institute - National Center for Sleep Disorders Research. *66 Accidentes de tránsito en el Perú: ¿Qué nos dicen las cifras y qué debemos hacer?* (n.d.).

CCIMA Señalizaciones. Retrieved December 14, 2023, from <https://www.ccimasenalizaciones.pe/aprende-de-senales/335-accidentes-de-transito-en-el-peru-que-nos-dicen-las-cifras-y-que-debemos-hacer>

Calvo, D. (2019). Red Neuronal Convolucional CNN. Recuperado de <http://www.diegocalvo.es/redneuronal-convolucional/> (Fecha de último acceso: abril de 2019).

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. Cambridge, MA: MIT Press.